

# Programando en paralelo

Mauro Jaskelioff

16/05/2017

# Mergesort

- ▶ El algoritmo de ordenación mergesort es un clásico ejemplo de Divide & Conquer
- ▶ Dividimos la entrada en dos (*split*)
- ▶ Ordenamos recursivamente
- ▶ Juntamos las dos mitades ordenadas (*merge*)

# Ordenando listas con Mergesort

$msort : [Int] \rightarrow [Int]$   
 $msort [] = []$   
 $msort [x] = [x]$   
 $msort xs = \mathbf{let} (ls, rs) = split\ xs$   
 $\quad (ls', rs') = (msort\ ls \parallel msort\ rs)$   
 $\quad \mathbf{in} merge\ (ls', rs')$

$split : [Int] \rightarrow [Int] \times [Int]$   
 $split [] = ([], [])$   
 $split [x] = ([x], [])$   
 $split (x \triangleleft y \triangleleft zs) = \mathbf{let} (xs, ys) = split\ zs$   
 $\quad \mathbf{in} (x \triangleleft xs, y \triangleleft ys)$

## Mergesort (cont.)

```
merge                : [Int] × [Int] → [Int]
merge ([], ys)       = ys
merge (xs, [])        = xs
merge (x ∷ xs, y ∷ ys) = if x ≤ y then x ∷ merge (xs, y ∷ ys)
                        else y ∷ merge (x ∷ xs, ys)
```

# Mergesort: Trabajo

- ▶  $W_{split}(n) \in O(n)$
- ▶  $W_{merge}(n) \in O(n)$
- ▶  $W_{msort}(n) = c_0 n + 2W_{msort}(\frac{n}{2}) + c_1 n + c_2$
- ▶ Por lo tanto

$$W_{msort}(n) \in O(n \lg n)$$

# Mergesort: Profundidad

- ▶  $S_{split}(n) \in O(n)$
- ▶  $S_{merge}(n) \in O(n)$
- ▶  $S_{msort}(n) = k_0 n + S_{msort}(\frac{n}{2}) + k_1 n + k_2$
- ▶ Por lo tanto,

$$S_{msort} \in O(n)$$

- ▶ ¡No es muy paralelizable!
- ▶ ¿Cuál es el problema?

# Paralelizando Mergesort

- ▶ El problema no es el algoritmo, sino las listas
- ▶ *split* y *merge* son poco paralelizables.
- ▶ En general, las listas no son buenas para paralelizar

*La elección de la estructura de datos influye en la profundidad del algoritmo*

- ▶ En lugar de listas trabajemos con el siguiente tipo de árboles:

**data** *BT* *a* = *Empty* | *Node* (*BT* *a*) *a* (*BT* *a*)

- ▶ ¡Podemos implementar *msort* sobre árboles con  $W(n) \in O(n \lg n)$  y  $S(n) \in O((\lg n)^3)$ !

# Árboles de búsqueda

- ▶ En elemento de  $BT$   $a$  está ordenado sii
  1. Es el árbol *Empty*
  2. Es un *Node*  $l \times r$  y además,
    - ▶  $l$  está ordenado
    - ▶  $r$  está ordenado
    - ▶ todos los elementos en  $l$  son  $\leq x$
    - ▶  $x <$  todo elemento de  $r$
  3. Un árbol ordenado induce una lista ordenada

$$listar : BT\ a \rightarrow [a]$$

$$listar\ Empty = []$$

$$listar\ (Node\ l \times r) = listar\ l \mathbin{++} [x] \mathbin{++} listar\ r$$

- ▶ Es un recorrido *inorder*



# Mergesort sobre árboles

- ▶ ¿Qué pinta tendrá el *msort* sobre árboles?

$$\begin{aligned} \text{msort} &: BT\ a \rightarrow BT\ a \\ \text{msort}\ \text{Empty} &= \text{Empty} \\ \text{msort}\ (\text{Node}\ l\ x\ r) &= \dots\ \text{msort}\ l\ \dots\ \text{msort}\ r\ \dots \end{aligned}$$

- ▶ Primer ventaja:  $W_{split} \in O(1)$ ,  $S_{split} \in O(1)$
- ▶ Hacemos un *merge* de *msort* *l*, *msort* *r*, y de *x*.

$$\begin{aligned} \text{msort} &: BT\ a \rightarrow BT\ a \\ \text{msort}\ \text{Empty} &= \text{Empty} \\ \text{msort}\ (\text{Node}\ l\ x\ r) &= \text{let } (l', r') = \text{msort}\ l \parallel \text{msort}\ r \\ &\quad \text{in merge}\ (\text{merge}\ l'\ r') \\ &\quad\quad (\text{Node}\ \text{Empty}\ x\ \text{Empty}) \end{aligned}$$

- ▶ Queremos que  $W_{merge} \in O(n)$  y  $S_{merge}$  mejor que  $O(n)$ .

## Merge de árboles (i)

- ▶ ¿Cómo definir *merge* sobre árboles?
- ▶ Consideremos el siguiente caso

$$\text{merge}\left(\begin{array}{c} 3 \\ / \quad \backslash \\ 1 \quad 5 \end{array}, \begin{array}{c} 4 \\ / \quad \backslash \\ 2 \quad 6 \end{array}\right)$$

- ▶ Elegimos guiarnos por el primer argumento.

$$\text{merge}\left(\begin{array}{c} 3 \\ / \quad \backslash \\ 1 \quad 5 \end{array}, \begin{array}{c} 4 \\ / \quad \backslash \\ 2 \quad 6 \end{array}\right) = \begin{array}{c} 3 \\ / \quad \backslash \\ \text{merge}(?, ?) \quad \text{merge}(?, ?) \end{array}$$

- ▶ El 1 seguro va a la izquierda, el 5 a la derecha

$$\text{merge}\left(\begin{array}{c} 3 \\ / \quad \backslash \\ 1 \quad 5 \end{array}, \begin{array}{c} 4 \\ / \quad \backslash \\ 2 \quad 6 \end{array}\right) = \begin{array}{c} 3 \\ / \quad \backslash \\ \text{merge}(1, ?) \quad \text{merge}(5, ?) \end{array}$$

## Merge de árboles (ii)

- Separamos el segundo argumento en árboles menores a 3 y mayores a 3

$$\text{merge}\left(\begin{array}{c} 3 \\ / \quad \backslash \\ 1 \quad 5 \end{array}, \begin{array}{c} 4 \\ / \quad \backslash \\ 2 \quad 6 \end{array}\right) = \begin{array}{c} 3 \\ / \quad \backslash \\ \text{merge}(1,2) \quad \text{merge}(5,4,6) \end{array}$$

- Finalmente

$$\text{merge}\left(\begin{array}{c} 3 \\ / \quad \backslash \\ 1 \quad 5 \end{array}, \begin{array}{c} 4 \\ / \quad \backslash \\ 2 \quad 6 \end{array}\right) = \begin{array}{c} 3 \\ / \quad \backslash \\ 1 \quad 5 \\ \backslash \quad / \\ 2 \quad 4 \quad 6 \end{array}$$

## Merge de árboles (ii)

- La implementación de *merge* es:

$$\begin{aligned} \text{merge} & : BT\ Int \rightarrow BT\ Int \rightarrow BT\ Int \\ \text{merge}\ Empty\ t_2 & = t_2 \\ \text{merge}\ (Node\ l_1\ \times\ r_1)\ t_2 & = \mathbf{let}\ (l_2, r_2) = \text{splitAt}\ t_2\ \times \\ & \qquad \qquad \qquad (l', r') = \text{merge}\ l_1\ l_2 \\ & \qquad \qquad \qquad \parallel \\ & \qquad \qquad \qquad \text{merge}\ r_1\ r_2 \\ & \mathbf{in}\ Node\ l'\ \times\ r' \end{aligned}$$

- donde *splitAt* se define:

$$\begin{aligned} \text{splitAt} & : BT\ Int \rightarrow Int \rightarrow Bt\ Int \times BT\ Int \\ \text{splitAt}\ Empty\ \_ & = (Empty, Empty) \\ \text{splitAt}\ (Node\ l\ \times\ r)\ y & = \mathbf{if}\ y < x\ \mathbf{then}\ \mathbf{let}\ (ll, lr) = \text{splitAt}\ l\ y \\ & \qquad \qquad \qquad \mathbf{in}\ (ll, Node\ lr\ \times\ r) \\ & \qquad \qquad \qquad \mathbf{else}\ \mathbf{let}\ (rl, rr) = \text{splitAt}\ r\ y \\ & \qquad \qquad \qquad \mathbf{in}\ (Node\ l\ \times\ rl, rr) \end{aligned}$$

# Profundidad de *merge*

- ▶ Sea  $h$  la altura del árbol.
- ▶  $S_{splitAt}(h) = k + S_{splitAt}(h - 1) \Rightarrow S_{splitAt}(h) \in O(h)$ .
- ▶ Sean  $h_1$  y  $h_2$  las alturas de los árboles argumento

$$S_{merge}(h_1, h_2) = k + S_{splitAt}(h_2) + \max(S_{merge}(h_1 - 1, h_{21}), S_{merge}(h_1 - 1, h_{22}))$$

donde  $h_{21}$  y  $h_{22}$  son las alturas de los árboles devueltos por *splitAt*

- ▶  $h_{21} \leq h_2, \quad h_{22} \leq h_2$

$$S_{merge}(h_1, h_2) \leq k + S_{splitAt}(h_2) + \max(S_{merge}(h_1 - 1, h_2), S_{merge}(h_1 - 1, h_2))$$

## Profundidad de *merge* (cont.)

- ▶ Continuamos aproximando...

$$S_{merge}(h_1, h_2) \leq k + S_{SplitAt}(h_2) + \max(S_{merge}(h_1 - 1, h_2), S_{merge}(h_1 - 1, h_2))$$

$$S_{merge}(h_1, h_2) \leq k' h_2 + S_{merge}(h_1 - 1, h_2)$$

- ▶ Sumamos  $h_1$  veces  $(k' h_2)$
- ▶ Por lo tanto,  $S_{merge}(h_1, h_2) \in O(h_1 \cdot h_2)$
- ▶ Si  $n$  es el tamaño del árbol, y el árbol está balanceado, entonces  $h = \lg n$ .

# Profundidad de *msort*

- ▶ Calculamos la profundidad de *msort*

$$S_{msort}(n) \leq k + \max(S_{msort}(\frac{n}{2}), S_{msort}(\frac{n}{2})) + \\ S_{merge}(\lg n, \lg n) + S_{merge}(2 \lg n, 1)$$

- ▶ El  $(2 \lg n)$  es porque *altura (merge l r)*  $\leq$  *altura l* + *altura r*
- ▶ Como  $S_{merge}(h_1, h_2) \in O(h_1 \cdot h_2)$

$$S_{msort}(n) \leq k + S_{msort}(\frac{n}{2}) + k_1(\lg n)^2 + k_2 \lg n$$

- ▶ Simplificando

$$S_{msort}(n) \leq k + S_{msort}(\frac{n}{2}) + k_3(\lg n)^2$$

- ▶ Por lo tanto

$$S_{msort}(n) \in O((\lg n)^3)$$

# Mentira!

- ▶ El análisis de la profundidad tiene un error grave.
- ▶ La profundidad de *merge* suponía árboles balanceados
- ▶ ¡Pero en *msort* llamamos a *merge* con el resultado de las llamadas recursivas!
- ▶ Lo arreglamos con una función *rebalance* ::  $BT\ a \rightarrow BT\ a$

```
msort                :  $BT\ a \rightarrow BT\ a$   
msort Empty          = Empty  
msort (Node l x r) = let (l', r') = msort l || msort r  
                    in rebalance (merge (merge l' r')  
                                   (Node Empty x Empty)  
                                   )
```



- ▶ Este algoritmo paralelo trabaja sobre árboles,
- ▶ pero la entrada podría ser una lista.
- ▶ Convertir una estructura secuencial en paralela puede no ser paralelizable.
- ▶ Por lo tanto no podríamos esperar una mejora lineal en la cant. de procesadores.

# Programando con Árboles

- ▶ Veamos operaciones sobre los siguientes árboles

**data**  $T\ a = \text{Empty} \mid \text{Leaf}\ a \mid \text{Node}\ (T\ a)\ (T\ a)$

- ▶ Map

$$\begin{aligned} \text{mapT} & : (a \rightarrow b) \rightarrow T\ a \rightarrow T\ b \\ \text{mapT}\ f\ \text{Empty} & = \text{Empty} \\ \text{mapT}\ f\ (\text{Leaf}\ x) & = \text{Leaf}\ (f\ x) \\ \text{mapT}\ f\ (\text{Node}\ l\ r) & = \text{let } (l', r') = \text{mapT}\ f\ l \parallel \text{mapT}\ f\ r \\ & \quad \text{in Node}\ l'\ r' \end{aligned}$$

- ▶ Si suponemos que  $W_f \in O(1)$  y  $S_f \in O(1)$ 
  - ▶  $W_{(\text{mapT}\ f)} \in O(n)$
  - ▶  $S_{(\text{mapT}\ f)} \in O(\lg n)$

# Otras funciones

- Sumar todos los elementos de un árbol de enteros

$$\begin{aligned} \text{sumT} & : T \text{ Int} \rightarrow \text{Int} \\ \text{sumT Empty} & = 0 \\ \text{sumT (Leaf } x) & = x \\ \text{sumT (Node } l \ r) & = \mathbf{let} \ (l', r') = \text{sumT } l \ || \ \text{sumT } r \\ & \quad \mathbf{in} \ l' + r' \end{aligned}$$

- Aplanar un árbol de cadenas

$$\begin{aligned} \text{flattenT} & : T \text{ String} \rightarrow \text{String} \\ \text{flattenT Empty} & = [] \\ \text{flattenT (Leaf } xs) & = xs \\ \text{flattenT (Node } l \ r) & = \mathbf{let} \ (l', r') = \text{flattenT } l \ || \ \text{flattenT } r \\ & \quad \mathbf{in} \ l' ++ r' \end{aligned}$$

## Reduce

- ▶ Estas funciones se pueden escribir como un *reduceT*

$$\begin{aligned} \text{reduceT} & : (a \rightarrow a \rightarrow a) \rightarrow a \rightarrow T\ a \rightarrow a \\ \text{reduceT } f\ e\ \text{Empty} & = e \\ \text{reduceT } f\ e\ (\text{Leaf } x) & = x \\ \text{reduceT } f\ e\ (\text{Node } l\ r) & = \mathbf{let}\ (l', r') = \text{reduceT } f\ e\ l \\ & \quad \parallel \\ & \quad \text{reduceT } f\ e\ r \\ & \quad \mathbf{in}\ f\ l'\ r' \end{aligned}$$

- ▶  $sumT = reduceT (+) 0$
- ▶  $flattenT = reduceT (++) []$
- ▶ Si  $f \in O(1)$ , entonces  $W_{reduce}(n) \in O(n)$
- ▶ Si  $f \in O(1)$ , entonces  $S_{reduce}(n) \in O(\lg n)$

# Ejemplos

- ▶ Queremos saber la longitud (en palabras) de la línea con más palabras en un texto.
  - ▶ *lolile* : *String*  $\rightarrow$  *Int*
- ▶ Si tenemos una función *wordcount* : *String*  $\rightarrow$  *Int*, entonces

*lolile* = *reduceT* *max* 0 . *mapT* *wordcount* . *lines*

- ▶ *lines* divide una cadena en un árbol de líneas

# Contando palabras

- ▶ Contar palabras es igual de simple

$$\begin{aligned} \text{wordcount} &: \text{String} \rightarrow \text{Int} \\ \text{wordcount} &= \text{sumT} \cdot \text{mapT} (\lambda\_ \rightarrow 1) \cdot \text{words} \end{aligned}$$

- ▶  $\text{words} : \text{String} \rightarrow T \text{String}$ , divide una cadena en un árbol de palabras.
- ▶ En resumen:

$$\begin{aligned} \text{lolile} &= \text{reduceT} \text{ max } 0 \cdot \text{mapT} \text{ wordcount} \cdot \text{lines} \\ \text{wordcount} &= \text{reduceT} (+) 0 \cdot \text{mapT} (\lambda\_ \rightarrow 1) \cdot \text{words} \end{aligned}$$

# mapreduce

- ▶ Hacer un *mapT* y luego un *reduceT* es ineficiente
- ▶ *mapT* genera un árbol que es inmediatamente consumido por *reduceT*
- ▶ Las dos funciones se pueden combinar en una sola:

$$\begin{aligned} \text{mapreduce} & : (a \rightarrow b) \rightarrow (b \rightarrow b \rightarrow b) \rightarrow b \rightarrow T a \rightarrow b \\ \text{mapreduce } f \ g \ e &= \text{mr} \\ \text{where } \text{mr } \text{Empty} &= e \\ \text{mr } (\text{Leaf } a) &= f \ a \\ \text{mr } (\text{Node } l \ r) &= \text{let } (l', r') = \text{mr } l \ || \ \text{mr } r \\ &\quad \text{in } g \ l' \ r' \end{aligned}$$

- ▶ *mapreduce* nos da otro ejemplo del uso del alto orden para expresar patrones de programación como programas.

- ▶ En general, las listas no son muy paralelizables.
- ▶ Para paralelizar, conviene trabajar con otras estructuras, como por ejemplo árboles.
- ▶ Las funciones de alto orden nos permiten capturar patrones generales de recursión.